

Ejercicio 1:

Demstrar que si ~~A~~ los vectores no nulos p_1, p_2, \dots, p_n satisfacen $p_i^T A p_j = 0 \forall i \neq j$ y A es simétrica y pos. def. entonces los vectores son lin. indep.

Supongamos que los vectores no son linealmente independientes entonces podemos escribir a uno en términos de los demás, es decir,

$$p_i = \alpha_1 p_1 + \alpha_2 p_2 + \dots + \alpha_{i-1} p_{i-1} + \alpha_{i+1} p_{i+1} + \dots + \alpha_n p_n \quad p_i \neq 0$$

luego pre multiplicamos la ecuación anterior por $p_i^T A$ y obtenemos

$$p_i^T A p_i = \alpha_1 p_i^T A p_1 + \dots + \alpha_n p_i^T A p_n = 0 \leftarrow (p_i^T A p_j = 0 \forall i \neq j)$$

Sin embargo, como A es una matriz simétrica y positiva definida tenemos que $x^T A x \geq 0 \forall x \in \mathbb{R}^n$

\therefore Hemos llegado a una contradicción que vino de suponer que los vectores no eran linealmente independientes.

\therefore Los vectores son linealmente independientes

Ejercicio 2: De este resultado, ¿por qué el gradiente conjugado converge en como más n iteraciones.

Al ser linealmente independiente los vectores $\{p_i\}$ estos generan todo el espacio vectorial, en particular, $x^* - x_0$, con x^* óptimo y x_0 el inicial

Esto es $x^* - x_0 = \beta_1 p_1 + \dots + \beta_n p_n$. luego si multiplicamos por $p_i^T A$

obtenemos $p_i^T A (x^* - x_0) = \beta_i p_i^T A p_i$ (ya que $p_i^T A p_j = 0 \forall i \neq j$)

$$\therefore \beta_i = \frac{p_i^T A (x^* - x_0)}{p_i^T A p_i}$$

luego, sea x_k el resultado del método del gradiente conjugado tenemos que este se puede escribir como:


$$x_k = x_0 + \underbrace{\alpha_1 p_1 + \dots + \alpha_{k-1} p_{k-1}}_{\text{se cancelan por ser conjugados}} \text{ y pre multiplicando por } p_k^T A \text{ obtenemos}$$

$$p_k^T A x_k = p_k^T A x_0$$

$$\text{Así, } p_k^T A (x^* - x_0) = p_k^T A (x^* - x_k) = p_k^T A (b - A x_k) = -p_k^T r_k$$

$\therefore \beta_k = \frac{-p_k^T r_k}{p_k^T A p_k}$ que son el tamaño del paso generado por el método de gradiente \rightarrow converge en n pasos.

En sí, lo que sucede es que se está minimizando en una dimensión siguiendo al eje y posteriormente a la otra.



∴ Como se minimiza por la dirección, esto es a lo más en n pasos.

Las elipses representan las curvas de nivel cuando A es diagonal de ϕ

Ejercicio 3:

Muestre que la segunda condición de wolfe fuerte implica la condición de curvatura: $S_k^T y_k > 0$

la segunda condición de wolfe nos dice que

$$|\nabla f(x_k + \alpha_k p_k)^T p_k| \leq c_2 |\nabla f(x_k)^T p_k|$$

luego, de esto tenemos que

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq -c_2 |\nabla f(x_k)^T p_k| = -c_2 \nabla f(x_k)^T p_k$$

restando $\nabla f(x_k)^T p_k$ de ambos lados obtenemos:

$$\nabla f(x_k + \alpha_k p_k)^T p_k - \nabla f(x_k)^T p_k \geq (c_2 - 1) \nabla f(x_k)^T p_k$$

luego, como la condición de wolfe nos dice que $c_2 < 1$, tenemos que

$$(c_2 - 1) \nabla f(x_k)^T p_k > 0$$

Así,

$$\nabla f(x_k + \alpha_k p_k)^T p_k - \nabla f(x_k)^T p_k > 0$$

si multiplicamos ambos lados por $\alpha_k (> 0)$ obtenemos

$$0 < \alpha_k \nabla f(x_k + \alpha_k p_k)^T p_k - \alpha_k \nabla f(x_k)^T p_k = \nabla f(x_k + \alpha_k p_k)^T (\alpha_k p_k) - \nabla f(x_k)^T (\alpha_k p_k)$$

$$= (\nabla f(x_k + \alpha_k p_k)^T - \nabla f(x_k)^T) \cdot \alpha_k p_k$$

$$= (\nabla f(x_k + \alpha_k p_k) - \nabla f(x_k))^T \cdot \alpha_k p_k > 0$$

luego, como $y_k = \nabla f(x_k + \underbrace{\alpha_k p_k}_{S_k}) - \nabla f(x_k)$ y $S_k = \alpha_k p_k$ tenemos:

$$y_k^T S_k > 0$$

EJERCICIO 4: verificar que B_{k+1} y H_{k+1} son inversas

Por construcción podemos suponer B_k, H_k inversas (B_0, H_0 lo son + inducción)
 luego, para probar que son inversas basta ver que $B_{k+1}H_{k+1} = I$.

$$B_{k+1}H_{k+1} = B_{k+1} [(I - \rho_k S_k y_k^T) H_k (I - \rho_k y_k S_k^T) + \rho_k S_k S_k^T]$$

Notamos que $B_{k+1}S_k = y_k$ entonces:

$$= (B_{k+1} - \rho_k y_k y_k^T) H_k (I - \rho_k y_k S_k^T) + \rho_k y_k S_k^T$$

$$\text{luego } B_{k+1} = B_k \bullet \frac{\rho_k S_k S_k^T B_k}{S_k^T B_k S_k} + \frac{y_k y_k^T}{y_k^T S_k} \quad \text{y } \rho_k y_k y_k^T = \frac{y_k y_k^T}{y_k^T S_k}$$

$$= (B_k - \frac{\rho_k S_k S_k^T B_k}{S_k^T B_k S_k}) H_k (I - \rho_k y_k S_k^T) + \rho_k y_k S_k^T$$

como $B_k H_k = I$ por hipótesis tenemos:

$$(I - \frac{\rho_k S_k S_k^T B_k}{S_k^T B_k S_k}) (I - \rho_k y_k S_k^T) + \rho_k y_k S_k^T$$

Expandiendo obtenemos

$$I - \frac{\rho_k S_k S_k^T B_k}{S_k^T B_k S_k} - \rho_k y_k S_k^T + \frac{\rho_k S_k S_k^T B_k}{S_k^T B_k S_k} \rho_k y_k S_k^T + \rho_k y_k S_k^T$$

$$\text{luego, } \rho_k \frac{B_k S_k S_k^T B_k}{S_k^T B_k S_k} y_k S_k^T = \frac{1}{S_k^T y_k} \cdot \frac{B_k S_k S_k^T}{S_k^T B_k S_k} y_k S_k^T$$

luego como $B_k S_k$ es escalar, cancelamos $S_k^T y_k$

$$= \frac{B_k S_k S_k^T}{S_k^T B_k S_k} \Rightarrow \frac{B_k S_k S_k^T}{S_k^T B_k S_k} = \frac{B_k S_k S_k^T}{S_k^T B_k S_k} \rho_k y_k S_k^T$$

$$B_{k+1}H_{k+1} = I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{B_k S_k S_k^T}{S_k^T B_k S_k} \rho_k y_k S_k^T$$

$$\therefore B_{k+1}H_{k+1} = I$$

Ejercicio 1:

Demstrar que si ~~A~~ los vectores no nulos p_1, p_2, \dots, p_n satisfacen $p_i^T A p_j = 0 \forall i \neq j$ y A es simétrica y pos. def. entonces los vectores son lin. indep.

Supongamos que los vectores no son linealmente independientes entonces podemos escribir a uno en términos de los demás, es decir,

$$p_i = \alpha_1 p_1 + \alpha_2 p_2 + \dots + \alpha_{i-1} p_{i-1} + \alpha_{i+1} p_{i+1} + \dots + \alpha_n p_n$$

Luego, premultiplicamos la ecuación por $p_j^T A$ y obtenemos

$$\underbrace{p_j^T A p_i}_0 = \alpha_j p_j^T A p_j \quad \text{luego, al ser } A \text{ positiva definida } p_j^T A p_j > 0$$

(por conjugados)

$$\text{Así, } \alpha_j = 0$$

Aplicando esto para $j=1, 2, \dots, n; j \neq i$ tenemos que

$$\alpha_j = 0 \quad \forall j=1, 2, \dots, n, j \neq i$$

$\therefore \{p_1, \dots, p_n\}$ es linealmente independiente.